תרגיל 3 למידה חישובית בייסיאנית אופק כרונה

שאלה 1

נתון כי $y_i = h(x_i)^T\theta + \eta_i$ כאשר $\eta_i \sim N(0,\sigma_i^2)$

לכן $y = H\theta + \eta$ כאשר $\eta \sim N(0, diag(\sigma_1^2,\dots,\sigma_N^2))$

אי לכן $p(y|\theta) = N(y; H\theta, D)$ כאשר $D = diag(\sigma_1^2,\dots,\sigma_N^2)$

שאלה 2

נמצא את $\theta$ שממקסם את $\log p(y|\theta) = -\frac{1}{2}(y-H\theta)^T D^{-1}(y-H\theta) + const$

נגזור $\nabla_\theta \log p(y|\theta) = \frac{1}{2}H^T 2D^{-1}(y-H\theta) = H^T D^{-1}y - H^T D^{-1}H\theta$

נשווה לאפס $H^T D^{-1}y - H^T D^{-1}H\theta = 0 \Leftarrow H^T D^{-1}H\theta = H^T D^{-1}y$

אז $\hat{\theta}^{MLE} = (H^T D^{-1}H)^{-1}H^T D^{-1}y$

שאלה 3

מהנתון $p(\theta) = N(\theta; \mu_0, \Sigma_0) \propto \exp(-\frac{1}{2}(\theta-\mu_0)^T \Sigma_0^{-1}(\theta-\mu_0))$

$p(y|\theta) = N(y; H\theta, D) \propto \exp(-\frac{1}{2}(y-H\theta)^T D^{-1}(y-H\theta))$

$\Leftarrow p(\theta|y) \propto p(\theta)\cdot p(y|\theta) \propto \exp(-\frac{1}{2}(\theta-\mu_0)^T \Sigma_0^{-1}(\theta-\mu_0) - \frac{1}{2}(y-H\theta)^T D^{-1}(y-H\theta))$

נשתמש ב- derivative trick

$$\nabla -\log p(\theta|y) = \frac{1}{2}(2\Sigma_0^{-1}(\theta-\mu_0) - 2H^T D^{-1}(y-H\theta))$$

$$= \Sigma_0^{-1}\theta - \Sigma_0^{-1}\mu_0 - H^T D^{-1}y + H^T D^{-1}H\theta$$

$$= (\Sigma_0^{-1} + H^T D^{-1}H)\theta - (\Sigma_0^{-1}\mu_0 + H^T D^{-1}y)$$

$$= (\Sigma_0^{-1} + H^T D^{-1}H)(\theta - (\Sigma_0^{-1} + H^T D^{-1}H)^{-1}(\Sigma_0^{-1}\mu_0 + H^T D^{-1}y))$$

$\Leftarrow p(\theta|y) = N(\theta; \mu_{\theta|D}, \Sigma_{\theta|D})$ כאשר $\Sigma_{\theta|D} = (\Sigma_0^{-1} + H^T D^{-1}H)^{-1}$ , $\mu_{\theta|D} = \Sigma_{\theta|D}(\Sigma_0^{-1}\mu_0 + H^T D^{-1}y)$

שאלה 4

$k$ הינו מטריצת גרהם ולכן PSD $\Leftarrow$ קיימת מטריצה $R$ כך ש- $k=R^TR$

נסמן ב- $R_i$ את העמודה ה-$i$ של $R$.

נשים לב כי $k_{ij}=R_i^TR_j$ לכן $k(x_i,x_j)=R_i^TR_j$

אבל אם נגדיר $f(x_i)=R_i$ נקבל כי $k(x_i,x_j)=\langle f(x_i),f(x_j)\rangle$ $(=f(x_i)^Tf(x_j))$

כעת נגדיר את $f,g$ כלל עבור $k_1,k_2$ בהתאמה ונקבל

$$k_1(x,y)\cdot k_2(x,y)=f(x)^Tf(y)g(x)^Tg(y)=\sum_i f_i(x)f_i(y)\cdot\sum_j g_j(x)g_j(y)=\sum_i\sum_j g_j(x)f_i(x)g_j(y)f_i(y)$$

שאלה 5

כבר בסעיף הקודם יכלנו לומר כי

$$k_1(x,y)\cdot k_2(x,y)=f(x)^Tf(y)g(y)^Tg(x)=tr(f(x)^T[f(y)g(y)^T]g(x))=tr([g(x)f(x)^T][f(y)g(y)^T])$$

כלומר כי $k_1(x,y)\cdot k_2(x,y)=tr([f(x)g(x)^T]^T[f(y)g(y)^T])$

לכן אם נגדיר $h:X\to V$ כאשר $V$ הוא מרחב המטריצות עם מכפלה פנימית פרובניוס

על ידי $h(x)=f(x)g(x)^T$ נקבל כי:

$$k_x(x,y)=k_1(x,y)\cdot k_2(x,y)=\langle h(x),h(y)\rangle=tr(h(x)^Th(y))=tr([f(x)g(x)^T]^T[f(y)g(y)^T])$$

קיבלנו כי $k_x(x,y)$ הוא מכפלה פנימית של אין וקטורים לכן, מתנאי מרסר, הוא קרנל.

שאלה 6

זו קרנל תקין. עבור שתי נקודות $x_1, x_2$ שונות

$$k = \begin{pmatrix} \exp(\beta\|g(x_1)-g(x_1)\|^2) & \exp(\beta\|g(x_1)-g(x_2)\|^2) \\ \exp(\beta\|g(x_2)-g(x_1)\|^2) & \exp(\beta\|g(x_2)-g(x_2)\|^2) \end{pmatrix} = \begin{pmatrix} 1 & \exp(\beta\|g(x_1)-g(x_2)\|^2) \\ \exp(\beta\|g(x_2)-g(x_1)\|^2) & 1 \end{pmatrix}$$

בשת נשים לב כי $\operatorname{tr} k = 2 > 0$ לכן $k$ הינו PSD רק אם $\det k > 0$

$$\det k = 1 - \exp(\beta\|g(x_1)-g(x_2)\|^2)\exp(\beta\|g(x_2)-g(x_1)\|^2) = 1 - \exp(2\beta\|g(x_1)-g(x_2)\|^2)$$

אי. עבור $g$ חח"ע $\|g(x_1)-g(x_2)\|^2 > 0 \Leftarrow \exp(2\beta\|g(x_1)-g(x_2)\|^2) > 1 \Leftarrow \det k < 0$

שאלה 7

זו קרנל תקין. עבור $k_1(x,y) = x^T y$ ו- $k_2(x,y) = 2\cdot x^T y$

מתקיים $k(x,y) = k_1(x,y) - k_2(x,y) = x^T y - 2\cdot x^T y = -x^T y$

$k_1$ הוא קרנל PSD לכן מטריצת גרהם $k_1 \succeq 0$ אך $k = -k_1 \Leftarrow k \preceq 0$ ולכן $k(x,y)$ זו קרנל PSD

שאלה 8

כן קרנל תקין. יהי סט דגימות $\{x^{(i)}\}_{i=1}^{I}$

$k_a, k_b$ קרנלים PSD לכן מטריצות גרהם $k_a$, $k_b$ ביחס לסט הדגימות הן PSD

כלומר $k_a^{(ij)} = k_a(x_a^{(i)}, x_a^{(j)})$ ו- $k_b^{(ij)} = k_b(x_b^{(i)}, x_b^{(j)})$

אז אם נגדיר מטריצת גרהם $k$ לקרנל $k$ כך ש- $k = k_a + k_b$

נקבל כי $k$ הוא גם PSD קרנל כי סכום של מטריצות PSD הוא PSD

שאלה 9

$$f_\theta(x) = k^T(x)\alpha + \eta \quad \Leftarrow \quad y = k\alpha + \eta$$

כדי $p(y|k,\sigma^2)$ הוא גאוסיאן כי הוא טרנספורמציה לינארית של גאוסיאנים

נחשב את התוחלת והשונות.

$$\mathbb{E}[y] = \mathbb{E}[k\alpha+\eta] = k\,\mathbb{E}[\alpha] + \mathbb{E}[\eta] = 0$$

$$Cov[y] = Cov[k\alpha+\eta] = Cov[k\alpha] + Cov[\eta] = k\,Cov[\alpha]\,k^T + Cov[\eta] = kk^{-1}k^T + \sigma^2 I = k + \sigma^2 I$$

$$\Leftarrow \quad p(y|k,\sigma^2) = N(y; 0, k+\sigma^2 I)$$

שאלה 10

$$p(y|\mu_\theta, \Sigma_\theta, \sigma^2) = (2\pi)^{\frac{d}{2}} \cdot |\Sigma_{\theta|D}|^{\frac{1}{2}} \cdot N(\mu_{\theta|D}; \mu, \Sigma) \cdot N(y; H\mu_{\theta|D}, \sigma^2 I)$$

$$\log p(y|\mu_\theta, \Sigma_\theta, \sigma^2) = \log\left(\frac{(2\pi)^{\frac{d}{2}} \cdot |\Sigma_{\theta|D}|^{\frac{1}{2}}}{(2\pi)^{d/2} \cdot |\Sigma|^{1/2} \cdot (2\pi\sigma^2)^{N/2}}\right) - \frac{1}{2}(\mu_{\theta|D} - \mu)^T \Sigma^{-1} (\mu_{\theta|D} - \mu) - \frac{1}{2\sigma^2}\|y - H\mu_{\theta|D}\|^2$$

$$\log p(y|\mu_\theta, \Sigma_\theta, \sigma^2) = \frac{1}{2}\log|\Sigma_{\theta|D}| - \frac{1}{2}\log|\Sigma| - \frac{N}{2}\log(2\pi\sigma^2) - \frac{1}{2}(\mu_{\theta|D} - \mu)^T \Sigma^{-1} (\mu_{\theta|D} - \mu) - \frac{1}{2\sigma^2}\|y - H\mu_{\theta|D}\|^2$$

חנוך פרקש

2.1

Function 1
best evidence d=2, worst evidence d=10

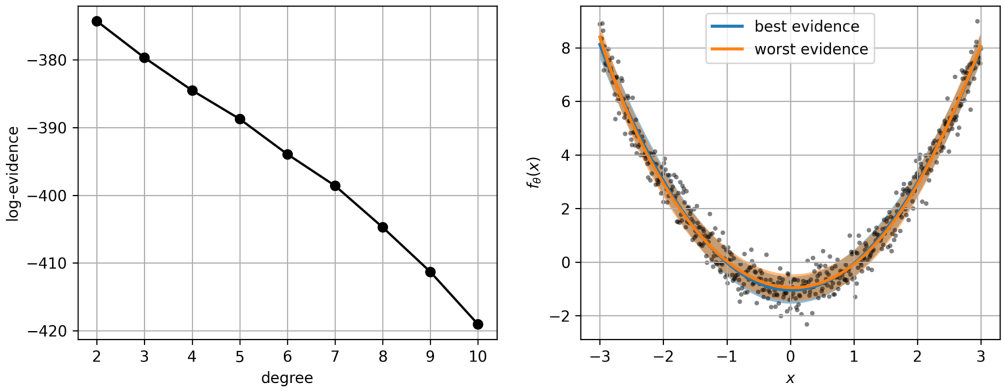


Function 2
best evidence d=3, worst evidence d=2

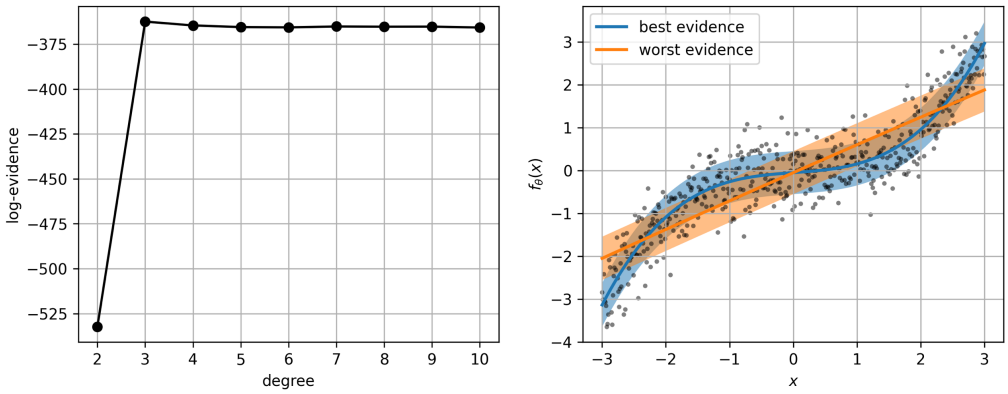


Function 3
best evidence d=6, worst evidence d=3

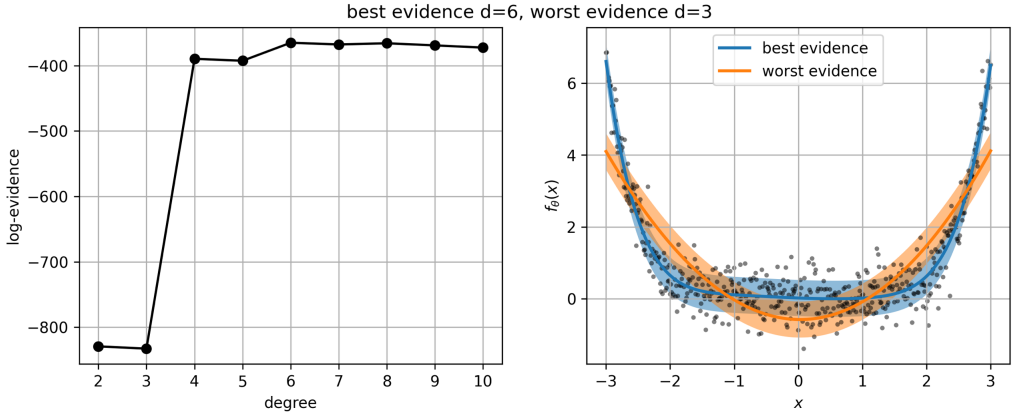


Function 4
best evidence d=5, worst evidence d=2

חלק 2.2




הערך המקסימלי תלוי במודל ובנתונים ולכן אין בהכרח שווה ערכו המדידה האמיתי.